Fase B — Limpieza y normalización de datos

Proyecto 2 y 3 · Dataset GEIH (DANE), periodo 202606 · Introducción a la Ciencia de Datos — Universidad del Valle

Grupo: Juan Camilo Vélez Ospina, Andrés Felipe Salcedo Buitrago, Geraldine Florez Rico y Daniela Orrego Alfonso

1. Punto de partida

La Fase A dejó un dataset de cerca de 53 mil personas encuestadas (una fila por persona) de la GEIH del periodo 202606. El diagnóstico mostró cuatro problemas que había que resolver antes de modelar:

- Casi todos los vacíos son estructurales y no errores: más del 94 % en semanas buscando empleo, 75 % en ingreso de otras fuentes y cerca del 45 % en ingreso laboral y horas trabajadas.
- Hay códigos tipo “no sabe / no informa” que se cuelan como números: el mínimo de otros ingresos era 98 y el máximo de semanas buscando empleo era 998.
- Hay atípicos en horas trabajadas (15,5 %, con registros de hasta 130 horas semanales) y en ingreso laboral (7,6 %).
- Los departamentos venían mezclados entre códigos y nombres.

2. Pasos del pipeline

1. Carga de los 6 CSV de la GEIH en un DataFrame con una fila por persona, conservando las llaves para revisar duplicados.
2. Diagnóstico de duplicados, nulos (estructurales vs. reales), texto, códigos especiales y atípicos (IQR y Z-score).
3. Limpieza determinista: códigos especiales a nulo, horas imposibles a nulo y regla estructural para otros ingresos.
4. Partición train/test 80/20 y tratamiento de los nulos reales con valores calculados solo con train.
5. Atípicos: se marcan con IQR, se decide si se conservan, y se aplica logaritmo a los ingresos.
6. Codificación de categóricas: Ordinal y One-Hot.
7. Escalado ajustado solo con train.
8. Guardado de `datos_limpios.parquet` (sin escalar) y `datos_limpios_escalado.parquet`.

3. Decisiones y justificación

- **Nulos estructurales vs. reales.** Un nulo es estructural cuando la pregunta no aplica a la persona (ingreso laboral y horas solo existen para ocupados; semanas buscando empleo solo para desempleados) y real cuando debería existir y falta. Los estructurales no se imputan: rellenarlos inventaría ingresos para los inactivos y, además, delataría el estado ocupacional.
- **Otros ingresos.** El vacío significa que la persona no declaró otros ingresos, así que se rellena con 0 y se crea la bandera `recibe_otros_ingresos`. Rellenar con la media habría inventado ingresos para el 75 % de la población.
- **Mediana y no media (horas trabajadas).** Los nulos reales de horas se rellenan con la mediana de train entre los ocupados. La variable tiene muchos atípicos (jornadas muy largas) que arrastrarían la media; la mediana representa la jornada típica.
- **Moda (categóricas).** En variables sin orden no existe un promedio, por lo que se usa la categoría más frecuente de train. Si una columna no tiene nulos reales, la moda queda como salvaguarda del pipeline.
- **Sin KNN y sin imputar el objetivo.** Con tan pocos nulos reales, KNN no mejora a la mediana y es mucho más costoso con 53 mil filas. El ingreso laboral, que es el objetivo propuesto, no se imputa porque rellenarlo contaminaría la evaluación del modelo. Los ocupados sin ingreso declarado o con ingreso 0 (ocupados sin remuneración, un proceso distinto a un salario) quedan fuera de la muestra de modelado.
- **Códigos "no sabe / no informa".** Los 98/99 de otros ingresos se convierten en nulo antes de sumar, y los 998/999 de semanas buscando empleo también; si no, se contarían como pesos o semanas reales.
- **Atípicos: conservar los de ingreso, corregir los imposibles.** El IQR y el Z-score se usan para detectarlos. Los ingresos altos son personas reales y bien pagadas, así que se conservan, se controla su efecto con el logaritmo y se deja una bandera para analizarlos aparte. En horas se conservan las jornadas de 61 a 112 horas (frecuentes en el trabajo informal) y solo se tratan como error las de más de 112 horas semanales (16 horas diarias los 7 días), que pasan a nulo y se imputan con la mediana.
- **Logaritmo con log1p.** Los dos ingresos tienen distribución muy asimétrica. Se usa log1p y no Box-Cox ni Yeo-Johnson porque acepta ceros, no aprende parámetros de los datos (sin riesgo de leakage) y se interpreta como un cambio porcentual. Una tabla de asimetría de todas las numéricas, en el notebook, respalda qué variables se transforman y cuáles no.
- **Ordinal vs. One-Hot.** Ordinal para `acceso_servicios` (Ninguno < Parcial < Completo) y `nivel_educativo` (de Sin educación a Posgrado), porque tienen un orden natural que un One-Hot perdería. One-Hot con `drop_first=True` para `sexo`, `departamento`,

`estado_civil` y `tipo_vivienda`, que no tienen jerarquía; `drop_first` evita la multicolinealidad perfecta que afecta a los modelos lineales.

- **Escalado según la variable.** RobustScaler para horas, cuartos y personas del hogar (usa mediana e IQR, así que los atípicos conservados no lo distorsionan); StandardScaler (Z-score) para la edad y las dos ordinales (distribuciones sin atípicos fuertes); MinMaxScaler para el logaritmo de otros ingresos, que tiene cerca del 75 % de ceros y dejaría el IQR en casi 0. El objetivo, las dummies y las banderas no se escalan.
- **Partición antes de imputar y escalar.** Las medianas, modas y escaladores se calculan solo con las filas de train (80 %, estratificado por estado ocupacional, semilla 42). La columna `particion` queda guardada para que la Fase C use el mismo split, y así test sigue siendo información que el modelo nunca vio.
- **Dos archivos de salida.** `datos_limpios.parquet` queda limpio y codificado pero sin escalar, porque la Fase C prohíbe normalizar antes del split y el escalado debe ajustarse dentro de train. `datos_limpios_escalado.parquet` muestra el resultado de la normalización ajustada solo con train.

4. Resultado de la ejecución

Las columnas quedan en cuatro grupos: control (`id_hecho`, `particion`, `estado_ocupacional`, `es_ocupado`, `muestra_modelado`), objetivo y derivadas (`ingreso_laboral`, `log_ingreso_laboral`, `ingreso_laboral_atipico`), referencia (`semanas_buscando_trabajo`, `ingreso_otras_fuentes`) y predictoras.

Cifras de la corrida (tabla `geih_2026_resumen` del notebook):

- Filas (personas): 53.131
- Train / test: 42.504 / 10.627 (80 % / 20 %)
- Muestra de modelado (ocupados con ingreso > 0): 28.760
- Ocupados sin ingreso declarado (excluidos) / con ingreso 0 (excluidos): 524 / 175
- Horas mayores a 112 convertidas a nulo: 5
- Valores 98/99 de otros ingresos convertidos a nulo: 38
- Mediana de horas usada para imputar: 44 horas semanales
- Columnas finales / predictoras: 65 / 55

5. Pendientes por verificar

- Confirmar en el diccionario del DANE los códigos 98/99 y 998/999 y la agrupación de `nivel_educativo` (variable P3042).

- Confirmar con el equipo de la Fase C que el objetivo es `log_ingreso_laboral` sobre los ocupados con ingreso mayor a 0.