Fase C — Implementación de modelos predictivos

Proyecto 2 y 3 · Dataset GEIH (DANE), periodo 202606 · Introducción a la Ciencia de Datos — Universidad del Valle

Grupo: Juan Camilo Vélez Ospina, Andrés Felipe Salcedo Buitrago, Geraldine Florez Rico y Daniela Orrego Alfonso

1. Pregunta y planteamiento

Pregunta de negocio: ¿qué tan bien se puede estimar el ingreso laboral mensual de una persona ocupada a partir de su perfil (edad, educación, horas trabajadas, departamento, hogar y vivienda)? Y, sin mirar un objetivo, ¿qué segmentos de trabajadores aparecen en los datos?

- **Tipo de problema:** regresión. El objetivo es `log_ingreso_laboral`, definido en la Fase B; las predicciones se devuelven a pesos con `np.expm1` para reportar el error en una unidad entendible.
- **Población:** 28.760 ocupados con ingreso mayor a 0 (`muestra_modelado`), con 54 variables predictoras.
- **Partición:** `train_test_split` 80/20 (22.997 / 5.763 personas), estratificado y con semilla 42. Es el mismo split de la Fase B: el notebook comprueba que coincide fila por fila con la columna `particion`.
- **Sin data leakage:** el escalado (RobustScaler, StandardScaler y MinMaxScaler, según la variable) va dentro de un `Pipeline` que se ajusta solo con train. Todas las métricas se calculan en test, con filas que el modelo nunca vio.

2. Modelos entrenados

- **Línea base (mediana):** predice siempre la mediana de train. Es el piso que cualquier modelo debe superar.
- **Regresión Lineal:** simple e interpretable; cada coeficiente se traduce en un efecto porcentual sobre el ingreso.
- **Random Forest:** 300 árboles con `min_samples_leaf=5` para no memorizar ingresos individuales.
- **Gradient Boosting** (`HistGradientBoostingRegressor`): hiperparámetros elegidos con `GridSearchCV` de 5 pliegues sobre train (tasa de aprendizaje 0,05, profundidad 8, regularización L2 = 1).
- **Red Neuronal (MLP):** dos capas ocultas (64 y 32 neuronas) con parada temprana.
- **K-Means (no supervisado):** segmentación con edad, horas, nivel educativo y log del ingreso; comparado con clustering jerárquico de Ward.

3. Comparación de desempeño (conjunto de prueba)

Modelo	MSE (log)	RMSE (log)	MAE (log)	R^2 (log)	MAE (COP)	Error mediano (COP)	R^2 CV (train)	R^2 train
Gradient Boosting	0,335	0,579	0,407	0,587	$811.497	$410.648	0,563	0,623
Random Forest	0,345	0,587	0,413	0,575	$815.467	$418.268	0,548	0,707
Red Neuronal (MLP)	0,361	0,601	0,427	0,556	$844.169	$464.654	0,519	0,592
Regresión Lineal	0,434	0,659	0,479	0,466	$954.735	$522.760	0,455	0,458
Línea base (mediana)	0,833	0,913	0,630	−0,026	$1.181.808	$750.905	—	−0,030

Métricas en test, salvo "R^2 CV (train)" (media de validación cruzada de 5 pliegues dentro de train) y "R^2 train" (solo para medir sobreajuste). Fila resaltada: modelo elegido.

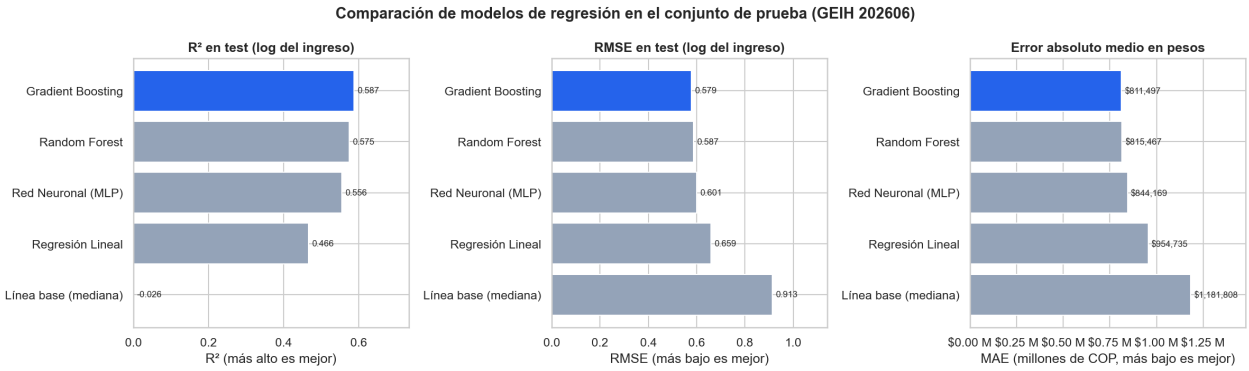


Figura 1. Comparación de R^2, RMSE y MAE en pesos en el conjunto de prueba.

Lectura. Los cuatro modelos superan con claridad a la línea base. Gradient Boosting es el mejor en las cuatro métricas pedidas y reduce el error absoluto medio a cerca de $811 mil, un 31 % menos que la línea base. Random Forest queda muy cerca, y la regresión lineal, aunque es la más débil, ya explica casi la mitad de la variación del log-ingreso. En la validación cruzada el orden de los modelos es el mismo y la desviación entre pliegues es pequeña (±0,01), así que la ventaja no depende de la partición.

Un MAE de 0,41 en log equivale a un error típico de ±40–50 % del ingreso. El error mediano en pesos (≈ $411 mil) es la mitad del MAE: la mayoría de las predicciones fallan por bastante menos que el promedio, y el MAE sube por unos pocos ingresos muy altos.

4. Justificación del modelo elegido: Gradient Boosting

Se elige **por precisión, respaldada por su capacidad de generalizar**, y se compensa su menor interpretabilidad con dos herramientas:

- **Precisión.** Mejor MSE, RMSE, MAE y R^2 en test (0,587) y mejor R^2 en validación cruzada (0,563 ± 0,009).
- **Generalización.** Su brecha entre train y test es pequeña (0,623 → 0,587). Random Forest, con un desempeño en test casi igual, tiene una brecha mucho mayor (0,707 → 0,575): memoriza más los datos de entrenamiento sin ganar nada en test.
- **Simplicidad de uso.** Entrena en segundos, no necesita escalado y sus hiperparámetros se eligieron con validación cruzada sin tocar test.

- **Interpretabilidad.** Es su punto débil. Se cubre con la importancia de variables por permutación (qué usa el modelo) y con la Regresión Lineal como modelo explicativo (cuánto pesa cada variable). Si el uso final exigiera explicar cada predicción a un tercero, la regresión lineal sería la alternativa: pierde unos 12 puntos de R^2 a cambio de una fórmula transparente.

Por qué no los otros. Random Forest es casi equivalente (≈ $4 mil más de MAE), pero sobreajusta más. La red neuronal tiene el R^2 más alto medido en pesos (0,41), pero queda tercera en todas las demás métricas; ese R^2 en pesos depende de unos pocos sueldos de decenas de millones, por eso no se usa para elegir. La regresión lineal es la más interpretable, pero su error es claramente mayor.

5. Qué aprendió el modelo

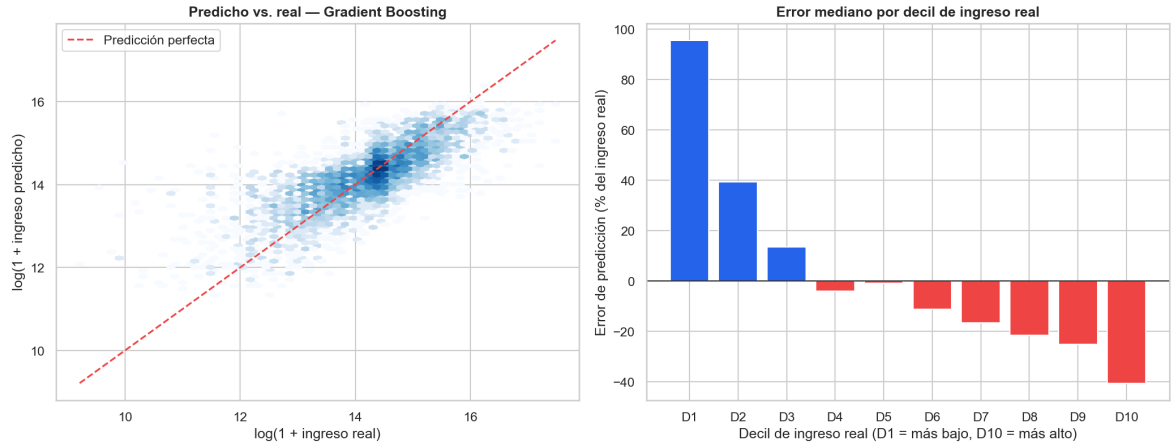


Figura 2. Predicho vs. real (izquierda) y error mediano por decil de ingreso real (derecha), Gradient Boosting.

- **Educación y horas trabajadas** son, por mucho, las variables más importantes (al desordenarlas el RMSE sube 0,23 y 0,20). Les siguen el departamento, el sexo y la edad; las características de la vivienda casi no aportan una vez se conoce la educación.
- **Brecha por sexo.** En la regresión lineal, ser mujer se asocia con un ingreso ≈ 20 % menor a igual educación, edad, horas, departamento y hogar. Una desviación estándar más de educación (≈ 1,5 niveles) se asocia con ≈ 54 % más de ingreso, y 8 horas semanales más con ≈ 21 % más.
- **Limitación: comprime los extremos.** El modelo acierta en la mitad de la distribución (deciles 4 y 5, error mediano de −4 % y −1 %), pero sobrestima los ingresos más bajos (en el decil 1 predice casi el doble) y subestima los más altos (−40 % en el decil 10). Le faltan variables que separen los extremos, como la ocupación o la formalidad. Sirve para estimar el ingreso típico de un perfil, no el de una persona puntual.

6. Segmentación con K-Means

Se probó k de 2 a 8. Se eligió **k = 4** porque Davies-Bouldin baja con fuerza hasta 4 (de 1,46 a 1,20) y luego casi no mejora, el Silhouette se mantiene estable entre 3 y 6, y con k = 4 el grupo más pequeño reúne el 13 % de las personas (con k = 5 aparece uno del 8 %). En test, K-Means obtiene **Silhouette 0,26 y Davies-Bouldin 1,20**, mejor que el clustering jerárquico de Ward en la misma muestra (0,19 y 1,47). El valor moderado del Silhouette indica fronteras difusas, algo esperable porque el ingreso y la edad varían de forma continua; los segmentos deben leerse como perfiles típicos.

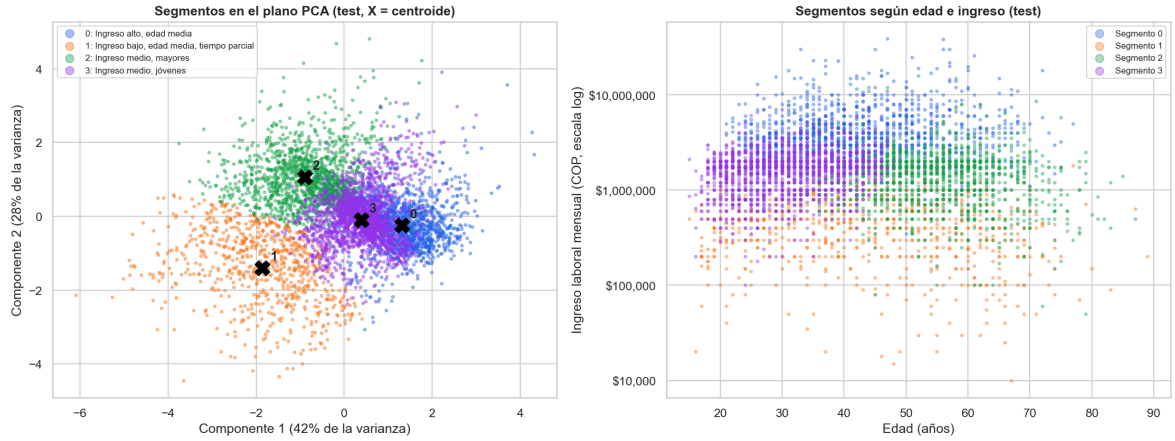


Figura 3. Segmentos en el plano PCA y según edad e ingreso (conjunto de prueba).

Segmento	% ocupados	Perfil (medianas y medias de train)
0 · Ingreso alto, edad media	25 %	~42 años, universitarios, 44 h/semana, ingreso mediano $3,4 millones; 82 % con todos los servicios
1 · Ingreso bajo, tiempo parcial	13 %	~44 años, educación media, 20 h/semana, ingreso mediano $400 mil; 71 % mujeres
2 · Ingreso medio, mayores	26 %	~55 años, hasta secundaria, 48 h/semana, ingreso mediano $1,5 millones; 68 % hombres
3 · Ingreso medio, jóvenes	37 %	~31 años, educación media, 46 h/semana, ingreso mediano $1,75 millones

Valor para el negocio. El segmento 1 reúne a trabajadoras que laboran pocas horas y ganan muy poco: allí se concentra el subempleo, y es el foco natural de programas de empleo de jornada completa o de cuidado infantil. El segmento 2 (mayores con baja educación y jornadas largas) apunta a temas de pensión y protección en la vejez.

7. Conclusiones y posibles mejoras

- Con variables sociodemográficas básicas se explica cerca del **59 % de la variación del log-ingreso**, con un error típico de ±40–50 %.
- La educación y las horas trabajadas son las palancas principales del ingreso; la brecha por sexo persiste aun controlando por ellas.
- **Más variables:** ocupación, rama de actividad, posición ocupacional, tamaño de empresa y formalidad (aportes a pensión), disponibles en otros módulos de la GEIH. Son las que pueden separar los ingresos extremos.
- **Más datos:** unir varios meses de la GEIH para tener más casos en departamentos pequeños y en ingresos altos.
- **Hiperparámetros y algoritmos:** búsqueda más amplia con `RandomizedSearchCV`, LightGBM o XGBoost, y regresión por cuantiles para entregar un rango de ingreso en vez de un solo valor.