Fase A — Análisis Exploratorio: los 3 hallazgos principales

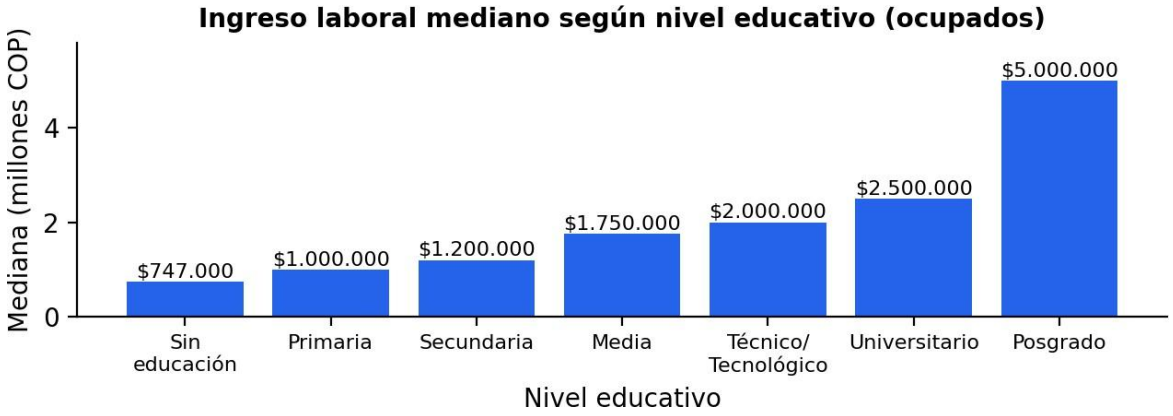
Proyecto 2 y 3 · Introducción a la Ciencia de Datos
Dataset: Gran Encuesta Integrada de Hogares (GEIH, DANE), periodo 202606
53.131 personas encuestadas

Exploramos la GEIH para entender qué características de las personas y los hogares se asocian con estar ocupado y con el ingreso laboral. Las cifras describen la muestra encuestada (sin factor de expansión), por lo que no equivalen a las tasas oficiales del DANE. Los ingresos se calculan sobre ocupados con ingreso mayor que cero.

1. El ingreso depende fuertemente de la educación

La mediana de ingreso laboral sube en cada nivel educativo: pasa de $747.000 sin educación a $2.500.000 con título universitario y a $5.000.000 con posgrado, es decir, 6,7 veces más. El mayor salto ocurre entre universitario y posgrado, donde la mediana se duplica.

Implicación: el nivel educativo es la variable candidata nº 1 para predecir ingreso en los modelos supervisados.



2. La brecha entre mujeres y hombres está en la participación y crece con la edad

El 67,3 % de los hombres está ocupado frente al 45,6 % de las mujeres, mientras que el desempleo es casi igual (5,7 % y 5,9 %): la diferencia viene de la inactividad, que alcanza al 48,5 % de las mujeres y al 27,0 % de los hombres. Entre quienes sí trabajan, la mediana de ingreso es similar en los grupos jóvenes, pero las mujeres ganan el 88 % de lo que ganan los hombres a los 35-44 años, el 64 % a los 55-64 y el 60 % después de los 65.

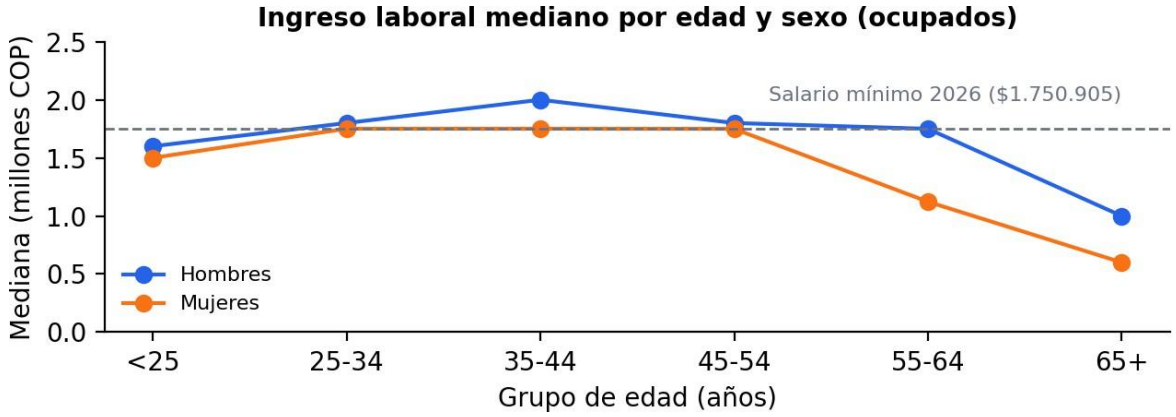
Implicación: el sexo tiene poder explicativo, pero debe usarse con cuidado ético en los modelos para no reproducir sesgo.



3. La mitad de los ocupados gana el salario mínimo o menos

La mediana del ingreso laboral es de $1.750.905, que coincide con el salario mínimo legal de 2026. Por encima hay una cola de ingresos altos: el 10 % mejor pagado supera los $4.000.000 y el 7,6 % de los ingresos son atípicos por la regla del rango intercuartílico (más de $4.500.000).

Implicación: en la limpieza hay que conservar estos atípicos porque son reales, y aplicar una transformación logarítmica al ingreso antes de modelar.



Otros hallazgos útiles para las siguientes fases

Calidad de datos: las horas trabajadas tienen 15,5 % de atípicos (más de 60 horas semanales) y registros de hasta 130 horas, que probablemente son errores de captura y se revisarán en la limpieza. Muchos nulos son estructurales: el ingreso solo existe para ocupados y las semanas de búsqueda solo para quienes buscan empleo.

Geografía: Chocó (20,9 %) y San Andrés y Providencia (19,8 %) tienen más del doble de la tasa de desempleo de la muestra (9,5 %), por lo que el departamento es una variable relevante.

Correlaciones: ninguna relación entre variables numéricas supera 0,30 (cuartos y personas en el hogar), así que el modelado deberá apoyarse también en variables categóricas como educación y sexo.