Proyecto 2 y 3 — Análisis, Limpieza y Modelado
GEIH — Gran Encuesta Integrada de Hogares (DANE)

Informe Final

Geraldine Florez Rico (2269476)
Daniela Orrego Alfonso (2510208)
Juan Camilo Velez Ospina (2510206)
Andrés Felipe Salcedo Buitrago
(2359304-3743)

INTRODUCCIÓN A LA CIENCIA DE DATOS

Ing. Héctor Fabio Ocampo Arbeláez

Universidad del Valle
Tuluá, Valle del Cauca
Semestre II – 2026

Contexto del dataset y pregunta de negocio

La Gran Encuesta Integrada de Hogares (GEIH) es la encuesta con la que el DANE mide el empleo, el desempleo y los ingresos en Colombia. En el Proyecto 1 cargamos los microdatos de junio de 2026 en una bodega de datos en PostgreSQL, alojada en Neon, con una tabla de hechos de situación laboral y seis dimensiones (persona, hogar y vivienda, ubicación, migración, estado ocupacional y tiempo). Para este proyecto seguimos con el mismo dataset: leemos la bodega directamente y de ahí armamos una fila por persona, 53.131 en total.

La pregunta que nos planteamos fue qué tan bien se puede estimar el ingreso laboral mensual de una persona ocupada a partir de su perfil (educación, horas trabajadas, edad, departamento y características del hogar) y si, sin darle ninguna pista al algoritmo, aparecen grupos de trabajadores parecidos entre sí. La respuesta ayuda a ver dónde están las brechas de ingreso y a quién podrían dirigirse programas de empleo o de formación.

Como el ingreso es una variable continua, lo tratamos como un problema de regresión y lo evaluamos con MSE, RMSE, MAE y R^2. Por eso no incluimos matriz de confusión ni curva ROC, que son métricas de clasificación; en su lugar usamos el gráfico de predicho contra real y el error por deciles de ingreso. Para los grupos usamos Silhouette y Davies-Bouldin.

FASE A: ANÁLISIS EXPLORATORIO

Revisamos las variables numéricas con histogramas, boxplots y correlaciones de Pearson y Spearman, y las categóricas con gráficos de barras, violines y dispersión. De todo eso salieron tres hallazgos que nos guiaron en el resto del trabajo.

El primero es que la educación pesa mucho en el ingreso. La mediana pasa de $747.000 en quienes no tienen educación a $2.500.000 con título universitario y a $5.000.000 con posgrado, es decir, 6,7 veces más (figura 1).

El segundo es que la diferencia entre hombres y mujeres está en la participación y no en el desempleo. Está ocupado el 67,3 % de los hombres frente al 45,6 % de las mujeres, mientras que el desempleo es casi igual (5,7 % y 5,9 %). La diferencia viene de la inactividad: 48,5 % de las mujeres contra 27,0 % de los hombres (figura 2). Entre quienes sí trabajan, el ingreso mediano de ellas es el 88 % del de ellos a los 35-44 años y baja a un 60-64 % pasados los 55.

El tercero es que la mitad de los ocupados gana alrededor del salario mínimo o menos: la mediana es $1.750.905, que coincide con el mínimo de 2026. El 10 % mejor pagado supera los $4.000.000 y el 7,6 % de los ingresos resultan atípicos según el criterio IQR. Al revisarlos vimos que son personas reales y bien pagadas, así que decidimos

conservarlos y transformar el ingreso con logaritmo.

Ninguna correlación entre variables numéricas fue fuerte (la mayor es 0,30, entre cuartos y personas del hogar). Eso nos dijo que ninguna variable sola explica el ingreso y que había que combinarlas con las categóricas.

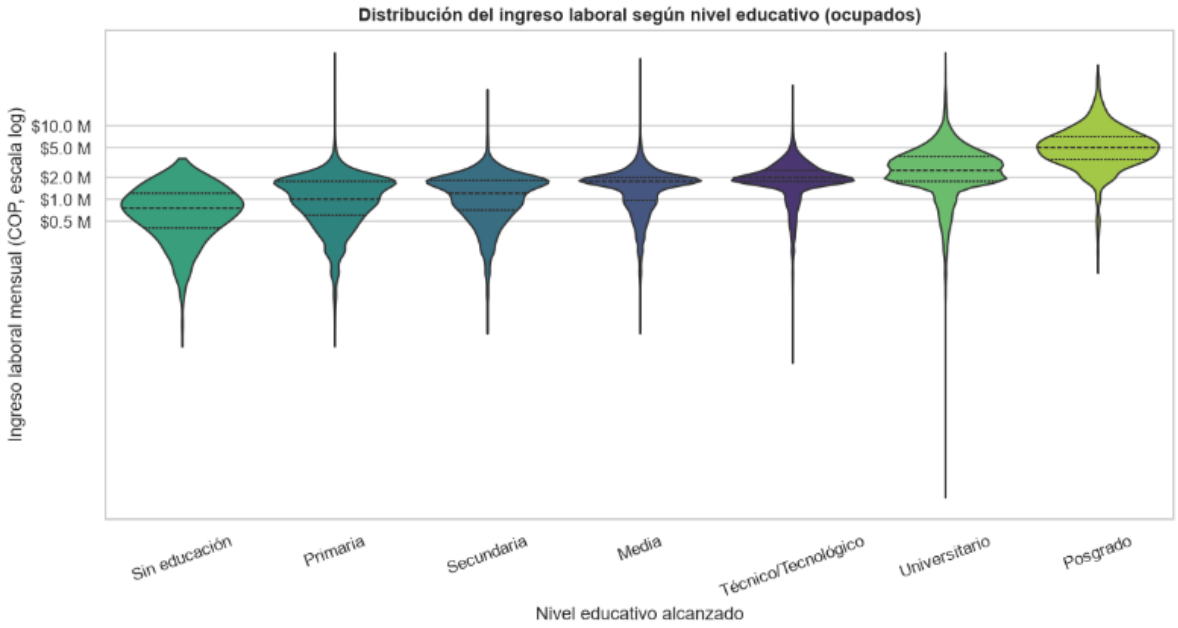


Figura 1. Ingreso laboral por nivel educativo. El ingreso sube por escalones con la educación

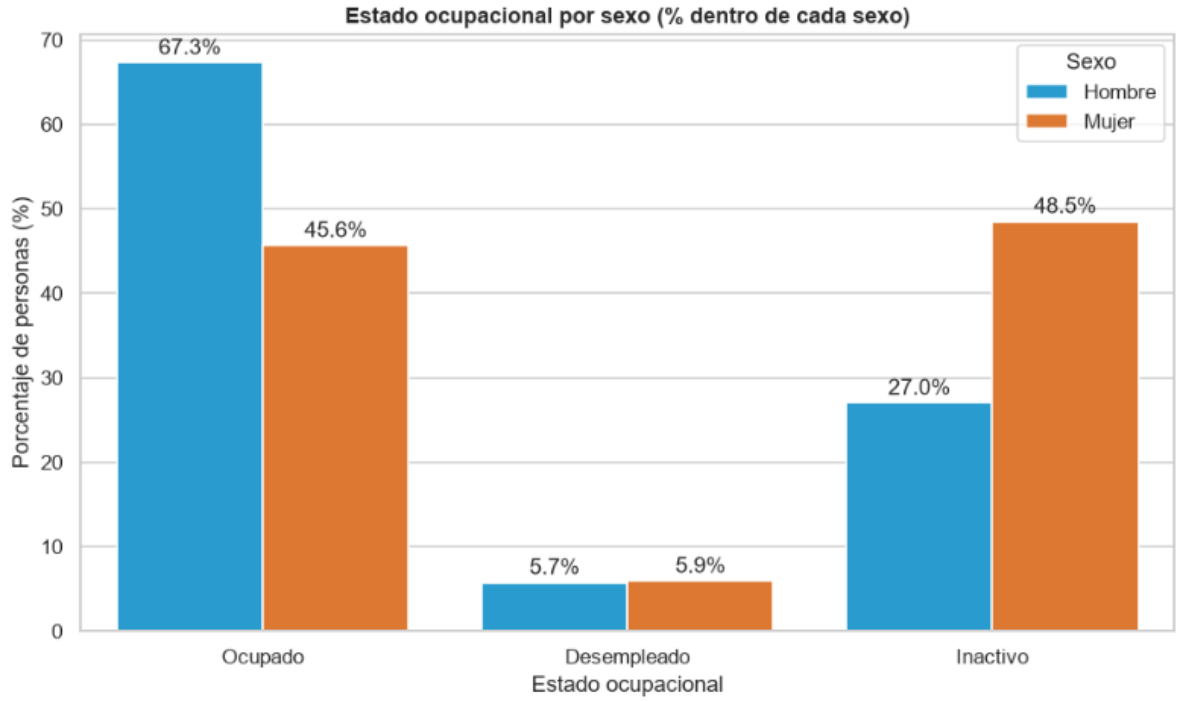


Figura 2. Estado ocupacional por sexo. La diferencia está en la inactividad.

FASE B: LIMPIEZA Y NORMALIZACIÓN

Antes de imputar o escalar hicimos la partición en entrenamiento y prueba (80/20, estratificada por estado ocupacional y con semilla 42): 42.504 personas en train y 10.627 en test. Lo hicimos en ese orden para evitar el data leakage, porque las medianas, las modas y los escaladores se calculan únicamente con las filas de train. La columna particion queda guardada en datos_limpios.parquet (53.131 filas y 65 columnas) para que los modelos usen exactamente el mismo conjunto de prueba. La tabla 1 resume lo que encontramos y lo que decidimos.

Problema encontrado	Decisión	Por qué
Duplicados: ninguna persona repetida; 718 filas idénticas en todas las variables	Conservar	Una persona es única por su llave; filas iguales son personas distintas, no copias.
Ingreso laboral nulo: 524 ocupados sin dato y 175 con ingreso 0	No imputar; modelar solo ocupados con ingreso > 0 (28.760)	Imputar el objetivo contaminaría la evaluación
Horas trabajadas: valores de hasta 130 h; 5 casos > 112 h	> 112 h a nulo; nulos reales con la mediana de train	112 h equivale a 16 h por 7 días; la mediana resiste atípicos y la media no.
Atípicos de ingreso (7,6 % sobre el límite IQR)	Conservar, aplicar log1p y agregar una bandera	Son personas reales; el logaritmo reduce la asimetría sin perder información.
Otros ingresos: 75 % vacío; 27 valores con código 98/99	98/99 a nulo; vacío a 0 con bandera; log1p; Min-Max	Vacío significa que no recibió otros ingresos; los códigos no son pesos.
Semanas buscando trabajo: más del 90 % de nulos estructurales	No imputar y no usar como predictora	Solo aplica a desempleados; delataría el estado ocupacional.
Categóricas nominales (sexo, departamento, estado civil, vivienda)	One-Hot con drop_first=True	No tienen orden; así se evita la multicolinealidad.
Categóricas con orden (nivel educativo, acceso a servicios)	Ordinal Encoding	Conserva el orden Ninguno < Parcial < Completo y Sin educación < ... < Posgrado
Escalas muy distintas	Robust (horas, cuartos, personas), Z-score (edad, educación) y Min-Max (otros ingresos)	Cada escalador va con la distribución de su variable y se ajusta solo con train.

Tabla 1. Decisiones de limpieza y su justificación.

Una aclaración sobre los datos: la bodega guarda el ingreso de otras fuentes ya sumado, así que no pudimos limpiar los códigos 98/99 columna por columna como se haría con los archivos originales. Lo que hicimos fue pasar a nulo los 27 valores que valen exactamente 98 o 99, que casi seguro corresponden a un solo código de “no sabe / no informa”. Es una aproximación y su efecto es pequeño, porque esa variable entra al modelo en logaritmo y no es de las más importantes.



Figura 3. El ingreso laboral tiene una cola larga a la derecha; con el logaritmo queda casi simétrico.

FASE C: MODELOS PREDICTIVOS Y COMPARACIÓN

Como objetivo usamos el logaritmo del ingreso laboral de los 28.760 ocupados con ingreso mayor que cero (22.997 en train y 5.763 en test), con 54 variables predictoras. El escalado va dentro de un Pipeline que se ajusta solo con train y todas las métricas se calculan en el conjunto de prueba. Entrenamos regresión lineal, Random Forest, Gradient Boosting y una red neuronal (MLP), además de una línea base que siempre predice la mediana, para saber cuánto mejoran los demás modelos. Los hiperparámetros de Gradient Boosting se eligieron con validación cruzada de 5 pliegues dentro de train.

Modelo	MSE (log)	RMSE (log)	MAE (log)	R^2 (log)	MAE (COP)	Error mediano (COP)	R^2 CV en train
Gradient Boosting	0,335	0,579	0,407	0,587	$810.427	$411.311	0,562
Random Forest	0,345	0,587	0,413	0,575	$815.319	$418.382	0,548
Red Neuronal (MLP)	0,361	0,601	0,427	0,556	$844.169	$464.654	0,519
Regresión Lineal	0,434	0,659	0,479	0,466	$954.735	$522.760	0,455

Línea base (mediana)	0,833	0,913	0,630	−0,026	$1.181.808	$750.905	—

Tabla 2. Métricas en el conjunto de prueba (el R^2 de validación cruzada se calculó dentro de train). Un MAE de 0,41 en logaritmo equivale, de forma aproximada, a equivocarse entre un 40 y un 50 % del ingreso.

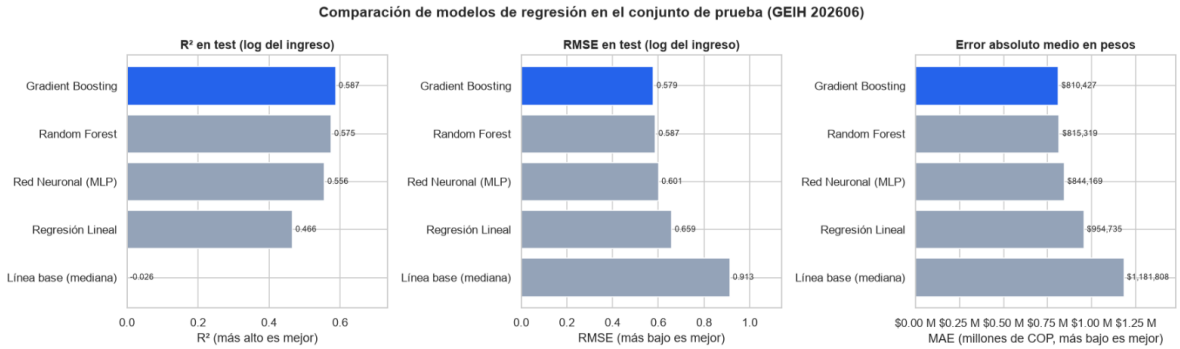


Figura 4. Comparación de los cinco modelos en test. Gradient Boosting aparece en azul.

Elegimos Gradient Boosting. Fue el mejor en las cuatro métricas, tanto en test como en validación cruzada, y la variación entre pliegues (±0,01) es mucho menor que la distancia entre modelos, así que el orden no depende de cómo se partieron los datos. También generaliza mejor: su R^2 baja de 0,623 en train a 0,587 en test, mientras que el de Random Forest baja de 0,707 a 0,575, o sea que memoriza más. Lo que perdemos es interpretabilidad. Para compensarlo miramos la importancia de las variables y la regresión lineal, que queda 12 puntos de R^2 por debajo pero da una fórmula fácil de explicar, y sería la opción si hubiera que justificar cada predicción ante un tercero.

Donde acierta y donde falla

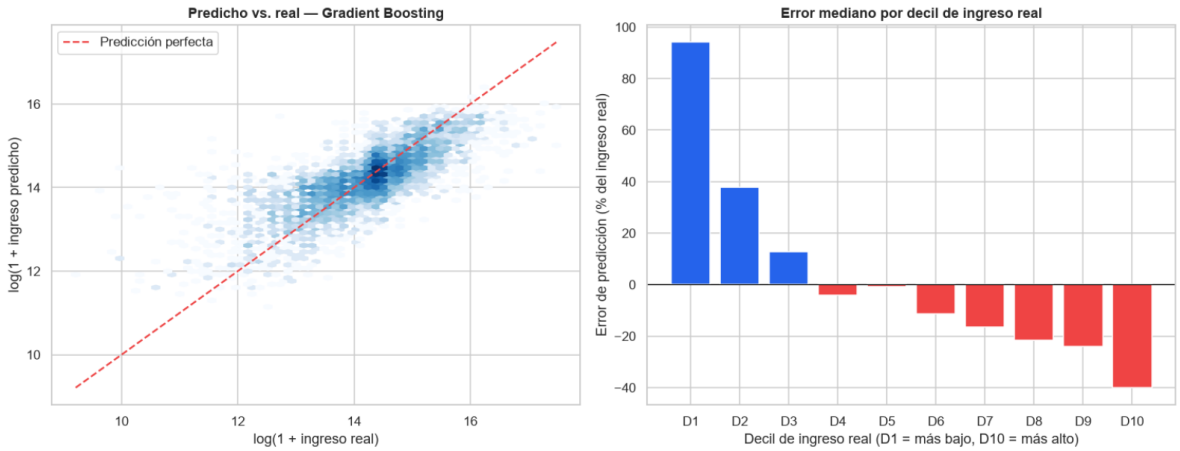


Figura 5. A la izquierda, predicho contra real (en logaritmo). A la derecha, error mediano por decil de ingreso real.

Las predicciones siguen la diagonal pero quedan comprimidas hacia el centro. En la mitad de la distribución (deciles D4 y D5, entre $1,2 y $1,75 millones) el error mediano es de −4

% y −1 %. En cambio, el modelo sobrestima los ingresos bajos (en el decil D1, de hasta $500 mil, predice casi el doble, un +94 %) y subestima los altos (en D10, desde $4 millones, predice un 40 % menos). Con edad, educación y horas no es posible distinguir a un médico especialista de un profesional recién graduado, ni a un trabajador por días de uno que cobra a destajo. En la práctica, el modelo estima bien el ingreso típico de un perfil, pero no sirve para detectar a quienes ganan muy poco o muchísimo.

Qué variables explican el ingreso

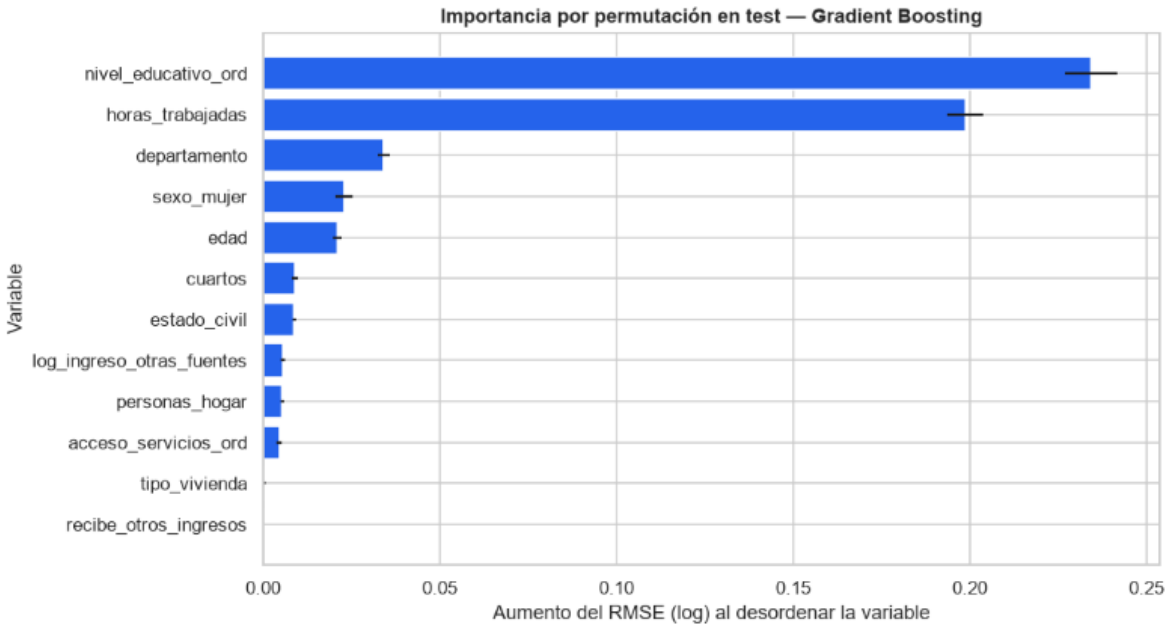


Figura 6. Importancia por permutación en test (aumento del RMSE al desordenar cada variable; el departamento se agrupó).

El ingreso lo explican sobre todo dos variables: el nivel educativo (el RMSE sube 0,23 al desordenarlo) y las horas trabajadas (0,20). Después vienen el departamento, el sexo y la edad, y las características de la vivienda casi no aportan cuando ya se conoce la educación. Con la regresión lineal se puede traducir esto a efectos porcentuales, dejando lo demás constante: una desviación estándar más de educación (cerca de 1,5 escalones, por ejemplo de Media a Universitario) se asocia con un ingreso 54 % mayor, 8 horas semanales más con un 21 % más, y ser mujer con un ingreso cerca de 20 % menor a igual educación, edad, horas, departamento y hogar. Son asociaciones y no causas: el modelo no explica por qué existe esa diferencia.

Segmentación de trabajadores con K-Means

Para agrupar a los ocupados usamos cuatro variables con significado claro: edad, horas trabajadas, nivel educativo e ingreso en logaritmo. Dejamos por fuera las dummies de departamento porque, en un algoritmo basado en distancias, 32 columnas binarias harían que los grupos fueran simplemente regiones. El escalador y K-Means se ajustaron con train y las métricas se calcularon en test.

Escogimos k = 4. El índice de Davies-Bouldin baja con fuerza hasta ahí (de 1,46 a 1,20) y después casi no mejora, el Silhouette se mantiene estable entre 0,26 y 0,27, y el grupo más pequeño todavía reúne al 13 % de las personas. Con k = 2 el Silhouette es mejor, pero solo separaría a quienes ganan más de quienes ganan menos. En test, K-Means obtuvo un Silhouette de 0,26 y un Davies-Bouldin de 1,20, por encima del clustering jerárquico de Ward sobre la misma muestra (0,22 y 1,38).

Segmento	Peso	Edad	Horas	Ingreso mediano	Mujeres	Perfil
0. Ingreso alto, edad media	25 %	42	44	$3.400.000	52 %	Universitarios; 82 % con todos los servicios en la vivienda
1. Ingreso bajo, tiempo parcia	13 %	44	20	$400.000	71 %	Educación media; subempleo
2. Ingreso medio, mayores	26 %	55	48	$1.500.000	32 %	Educación hasta secundaria; jornadas largas
3. Ingreso medio, jóvenes	37 %	31	46	$1.750.095	40 %	Educación media; el grupo más numeroso

Tabla 3. Perfil de los cuatro segmentos (cifras de train). Peso es el porcentaje de ocupados y Horas son las horas semanales.

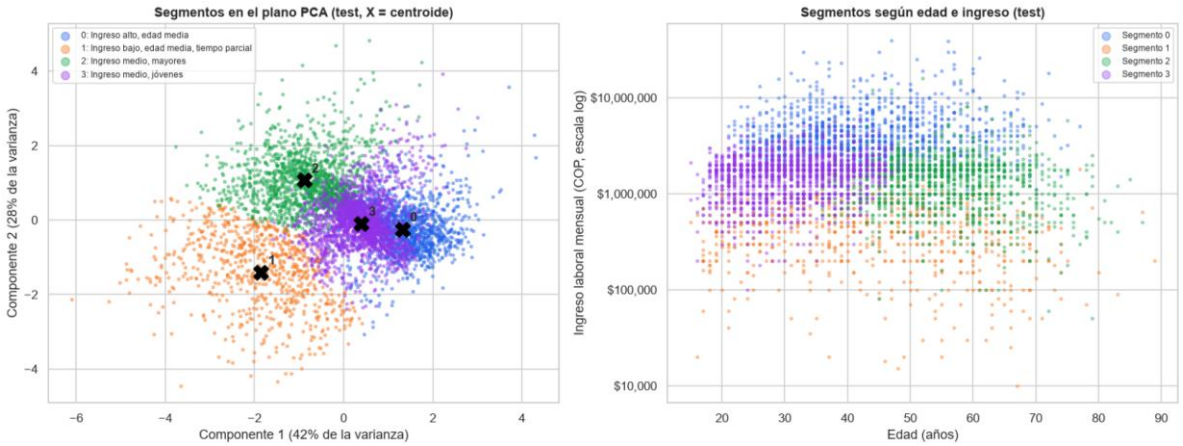


Figura 7. Segmentos en el plano de componentes principales (izquierda) y según edad e ingreso (derecha), sobre test.

El grupo que más nos interesó es el segmento 1: mayoritariamente mujeres que trabajan medio tiempo y ganan muy poco. Es el candidato natural para programas de empleo de jornada completa o de cuidado infantil. El segmento 2, con personas mayores de baja educación y jornadas largas, apunta más bien a temas de pensión y protección en la vejez. Un Silhouette de 0,26 indica fronteras difusas entre grupos, algo esperable cuando la edad y el ingreso varían de forma continua, así que los segmentos hay que leerlos como perfiles típicos y no como categorías cerradas.

FASE D: CONCLUSIONES Y POSIBLES MEJORAS

Con variables sociodemográficas básicas se logra explicar cerca del 59 % de la variación del logaritmo del ingreso, y todos los modelos superan con claridad a la línea base: el error medio baja de $1,18 millones a $810 mil, un 31 % menos. Aun así, un error típico de entre 40 y 50 % del ingreso es aceptable para estimar el ingreso de un perfil, pero no el de una persona en particular.

La educación y las horas trabajadas explican la mayor parte del ingreso. La diferencia por sexo, de cerca del 20 %, se mantiene incluso a igual educación, edad, horas y región, y es coherente con lo que vimos en la exploración: las mujeres participan menos en el mercado laboral y, cuando trabajan, ganan menos. La limitación principal del modelo es que comprime los extremos, justo donde más interesaría intervenir (los ingresos más bajos). Creemos que ahí faltan variables más que complejidad algorítmica. También pensamos que el modelo debe usarse para describir y dimensionar, y no para fijar o recomendar salarios, porque terminaría reproduciendo la desigualdad que mide.

Si tuviéramos más tiempo, lo primero sería sumar variables de otros módulos de la GEIH: ocupación, rama de actividad, posición ocupacional (asalariado o independiente), tamaño de la empresa y formalidad (si cotiza a pensión), que son las que separan los ingresos extremos. Después uniríamos varios meses de la encuesta para tener más casos en los departamentos pequeños y en los ingresos altos, haríamos una búsqueda de hiperparámetros más amplia y probaríamos LightGBM o XGBoost. Otra opción sería usar regresión por cuantiles para entregar un rango de ingreso en lugar de un solo valor, o clasificar por tramos si al negocio solo le importa saber si alguien gana menos del salario mínimo.