¿Cuánto gana un trabajador colombiano y qué tan bien se puede predecir?

Análisis, limpieza y modelado de la GEIH (DANE) · junio de 2026

Juan Camilo Velez Ospina · Andrés Felipe Salcedo Buitrago
Geraldine Florez Rico · Daniela Orrego Alfonso

Proyecto 2 y 3 · Introducción a la Ciencia de Datos · Universidad del Valle · Octubre de 2026

El problema

Mismo dataset del Proyecto 1: bodega dimensional de la GEIH en PostgreSQL (Neon)

53.131

personas encuestadas en la Gran Encuesta Integrada de Hogares del DANE, periodo 202606: una fila por persona, unida a 6 dimensiones.

28.760

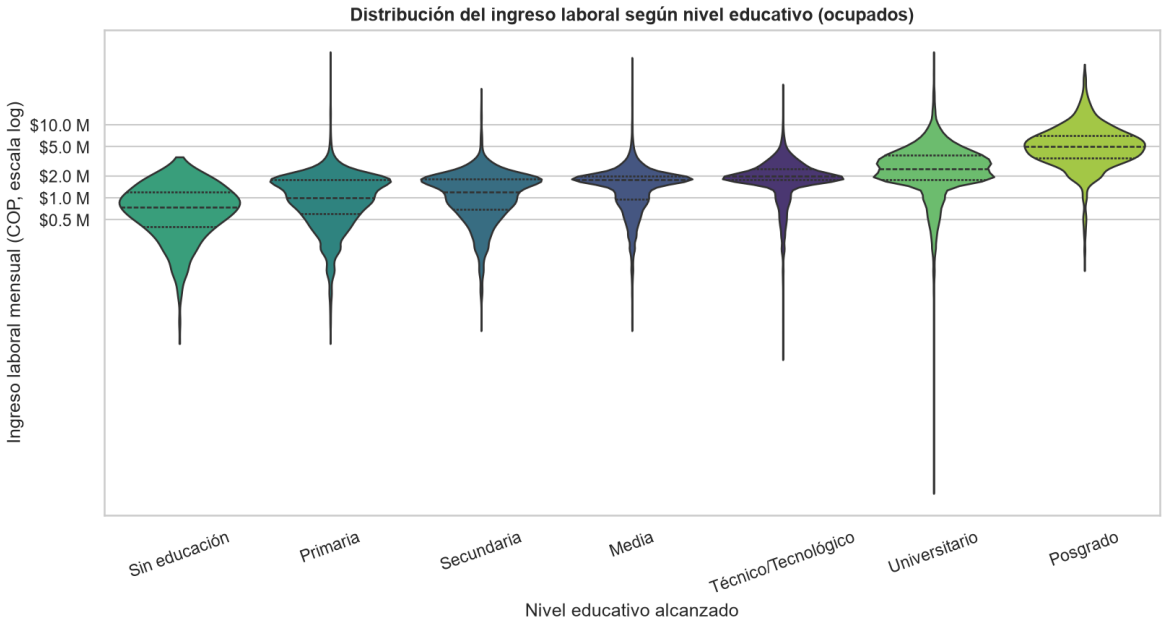
ocupados con ingreso laboral mayor que 0: la población con la que se entrena y evalúa el modelo.

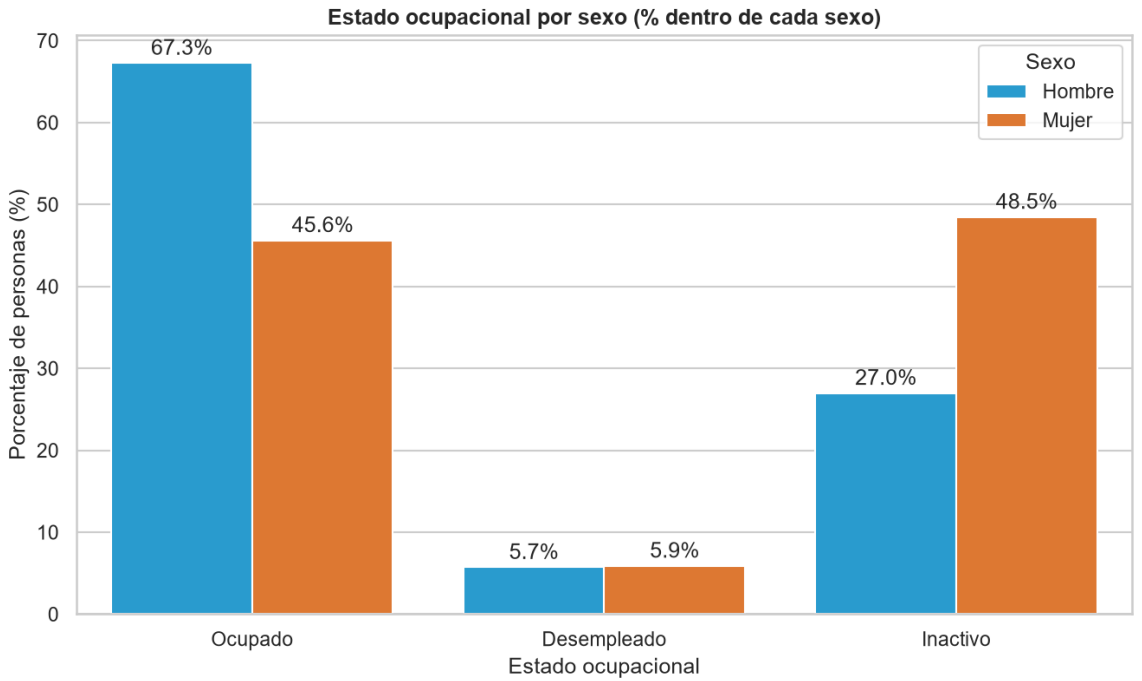
Pregunta de negocio: ¿qué tan bien se puede estimar el ingreso laboral mensual de una persona ocupada a partir de su perfil? Y sin decirle al algoritmo qué buscar, ¿qué segmentos de trabajadores aparecen?

Regresión (objetivo: log del ingreso) + segmentación con K-Means.

Lo que encontramos al explorar

Tres hallazgos que orientaron el modelo





1. La educación manda. La mediana sube de $747 mil sin educación a $5 millones con posgrado: 6,7 veces.

2. La brecha por sexo está en la participación. Ocupados: 67,3 % de los hombres y 45,6 % de las mujeres; desempleo casi igual (5,7 % y 5,9 %).

3. La mitad de los ocupados gana el salario mínimo o menos (mediana $1.750.905); el 7,6 % de ingresos atípicos son personas reales: se conservan.

Limpieza: decisiones con justificación

Regla central: nada que aprenda de los datos ve el conjunto de prueba (cero data leakage)

Problema	Decisión
524 ocupados sin ingreso y 175 con ingreso 0	No imputar el objetivo; modelar solo ingreso > 0
Horas hasta 130 h (5 casos > 112 h)	> 112 h a nulo; mediana de train (resiste atípicos)
Atípicos de ingreso (7,6 %)	Conservar + logaritmo + bandera
Otros ingresos: 75 % vacío, códigos 98/99	Vacío a 0 + bandera; 98/99 a nulo; log; Min-Max
Categorías nominales / con orden	One-Hot (drop_first) / Ordinal Encoding
Escalas distintas	Robust, Z-score y Min-Max, ajustados solo con train

Partición 80/20 **antes** de imputar y escalar: 42.504 en train y 10.627 en test. Resultado: **datos_limpios.parquet** (53.131 filas, 65 columnas).

Cómo se entrenó y evaluó

Cuatro modelos, una línea base y evaluación solo en el conjunto de prueba

- **Línea base:** predice siempre la mediana; es el piso que hay que superar.
- **Regresión Lineal:** simple e interpretable.
- **Random Forest:** captura no linealidades e interacciones.
- **Gradient Boosting:** árboles en secuencia; hiperparámetros con validación cruzada de 5 pliegues dentro de train.
- **Red Neuronal (MLP):** contraste flexible; necesita datos escalados.

Sin fugas

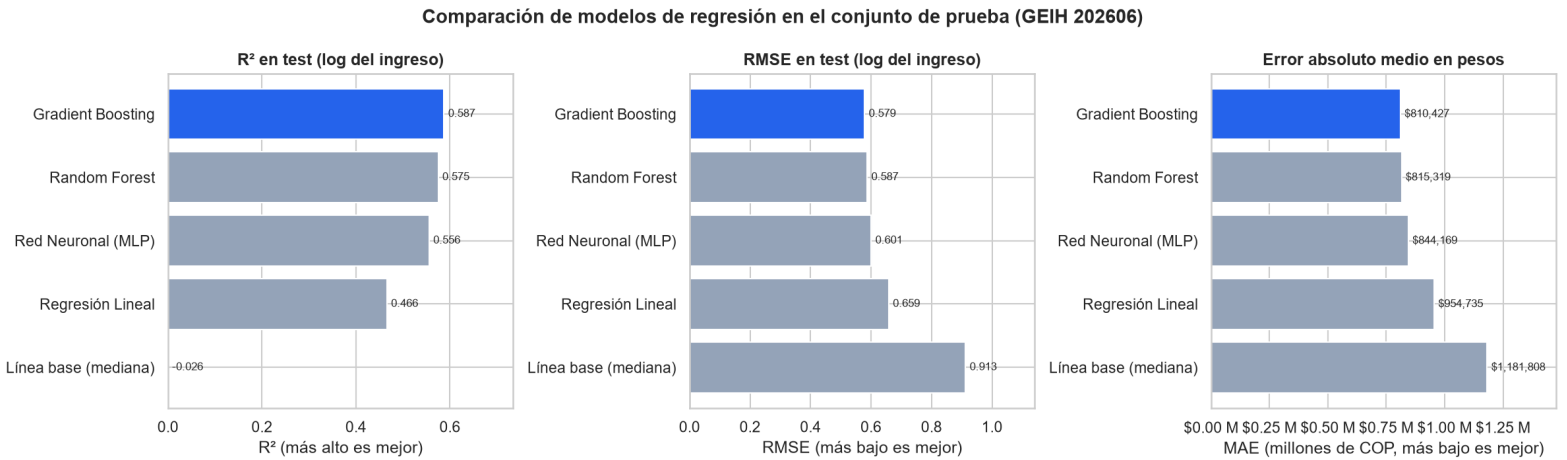
El escalado va dentro de un Pipeline que se ajusta solo con train. Las métricas (MSE, RMSE, MAE, R^2) se calculan solo en test.

54 variables

22.997 filas en train y 5.763 en test.

Resultados: Gradient Boosting es el mejor

Conjunto de prueba, objetivo en logaritmo; el error en pesos es el MAE



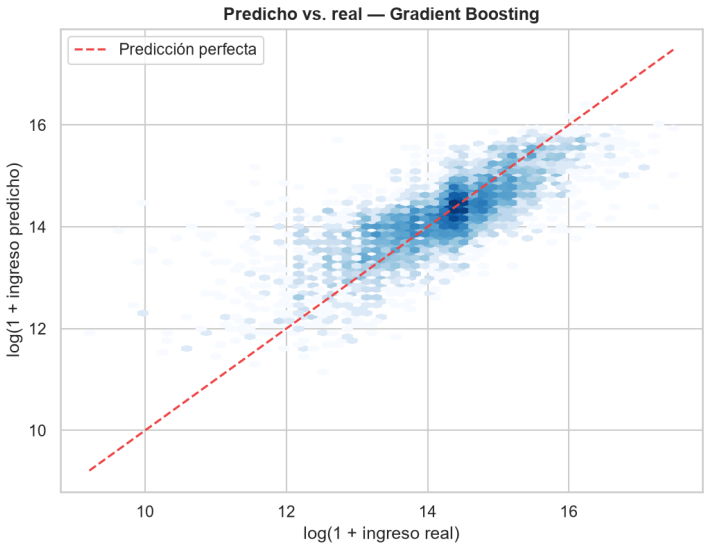
Modelo	R² (log)	RMSE (log)	MAE (COP)	R² CV train
Gradient Boosting	**0,587**	**0,579**	**$810.427**	**0,562**
Random Forest	0,575	0,587	$815.319	0,548
Red Neuronal (MLP)	0,556	0,601	$844.169	0,519
Regresión Lineal	0,466	0,659	$954.735	0,455
Línea base (mediana)	−0,026	0,913	$1.181.808	—

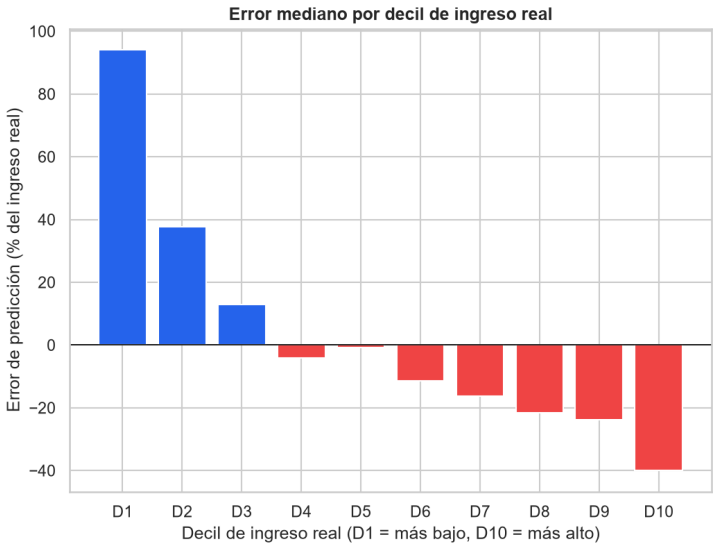
Por qué este modelo:

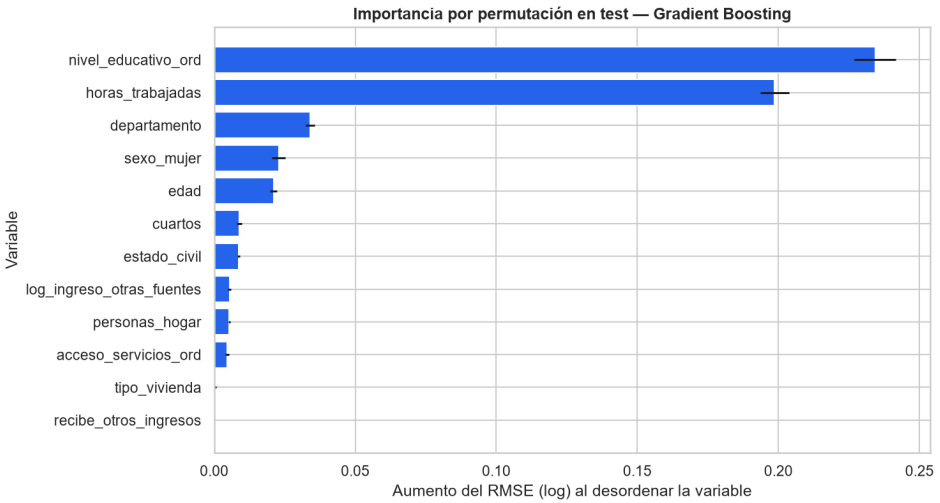
- Mejor en todas las métricas, también en validación cruzada.
- Sobreajusta menos: R² 0,623 → 0,587 (Random Forest: 0,707 → 0,575).
- Error medio 31 % menor que la línea base.

¿Dónde acierta y dónde falla?

El modelo comprime los extremos







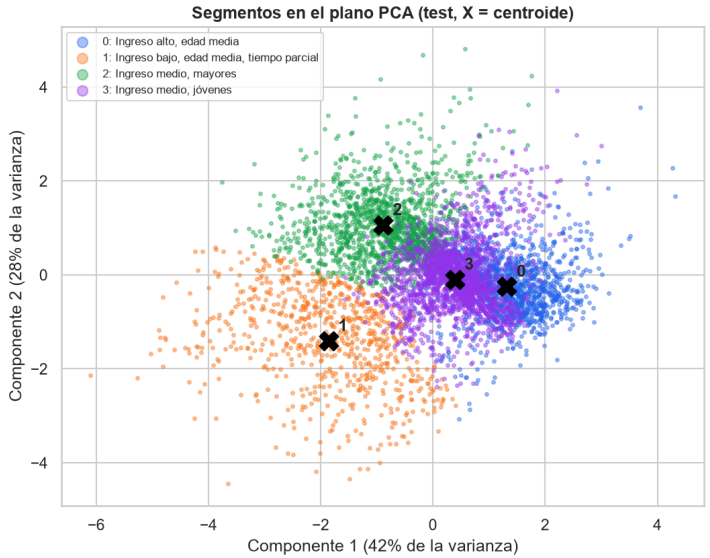
- Ingresos **bajos**: sobrestima (decil D1: +94 %).
- Ingresos **altos**: subestima (decil D10: −40 %).
- Centro de la distribución (D4–D5): error de −4 % y −1 %.

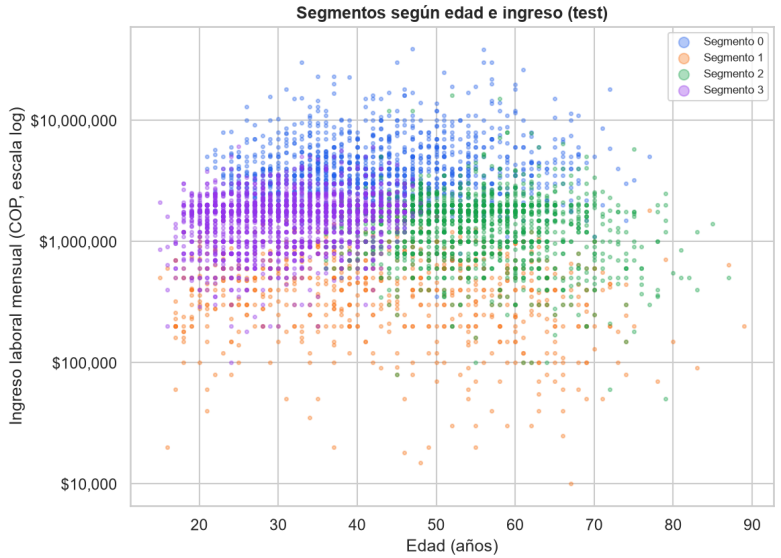
Educación y horas trabajadas explican casi todo el ingreso; luego departamento, sexo y edad. Con regresión lineal: +1,5 escalones educativos → +54 %; +8 horas → +21 %; ser mujer → −20 % a igual educación, edad, horas y región.

Sirve para estimar el ingreso **típico** de un perfil; no para detectar a quienes ganan muy poco o muchísimo.

Cuatro perfiles de trabajadores (K-Means, k = 4)

Silhouette 0,26 y Davies-Bouldin 1,20 en test; supera al clustering jerárquico de Ward (0,22 y 1,38)





Segmento	%	Horas	Ingreso mediano
0 · Ingreso alto	25	44	$3.400.000
1 · Bajo, tiempo parcial	**13**	**20**	**$400.000**
2 · Medio, mayores	26	48	$1.500.000
3 · Medio, jóvenes	37	46	$1.750.095

Segmento 1: 13 % de los ocupados, 71 % mujeres, 20 horas por semana y $400 mil de ingreso mediano. Es el foco natural para programas de empleo de jornada completa y cuidado infantil.

El segmento 2 (mayores con baja educación y jornadas largas) apunta a pensión y protección en la vejez.

Conclusiones y mejoras

Conclusiones

- Se explica el **59 %** de la variación del log-ingreso con datos básicos.
- Educación y horas son las palancas; la brecha por sexo (≈ 20 %) persiste a igual perfil.
- Útil para perfiles típicos, no para casos individuales.
- Uso responsable: describir y dimensionar, no fijar salarios.

Cómo mejorarlo

- **Más variables:** ocupación, rama de actividad, posición ocupacional, formalidad.
- **Más datos:** varios meses de la GEIH.
- **Otros algoritmos:** LightGBM, XGBoost, más búsqueda de hiperparámetros.
- **Regresión por cuantiles:** entregar un rango de ingreso.

Mensaje final: con lo básico se predice bien el ingreso típico; para llegar a los extremos hacen falta más variables, no más complejidad.