

PROYECTO 1: GEIH — GRAN ENCUESTA INTEGRADA DE HOGARES (DANE)

INTRODUCCIÓN A LA CIENCIA DE DATOS

DOCENTE

HÉCTOR FABIO OCAMPO ARBELÁEZ

GERALDINE FLOREZ RICO

2269476 -3743

DANIELA ORREGO

2510208 -3743

ANDRÉS FELIPE SALCEDO BUITRAGO

2359304 -3743

JUAN CAMILO VÉLEZ OSPINA

2510206 -3743

UNIVERSIDAD DEL VALLE

INGENIERÍA DE SISTEMAS

TULUÁ - VALLE DEL CAUCA

2026

FASE A — DISEÑO DE LA BODEGA DE DATOS

1. Introducción

Para el desarrollo de la bodega de datos se seleccionó como fuente de información la Gran Encuesta Integrada de Hogares (GEIH) del Departamento Administrativo Nacional de Estadística (DANE). El conjunto de datos contiene información relacionada con las características de las personas, los hogares y las viviendas, la situación laboral, la migración y los ingresos de la población.

El objetivo de la bodega de datos es organizar esta información bajo un modelo dimensional que facilite el análisis de la situación laboral de las personas encuestadas. Para ello, se diseñó un modelo estrella compuesto por una tabla de hechos denominada `FACT_SITUACION_LABORAL` y seis dimensiones: `DIM_PERSONA`, `DIM_HOGAR_VIVIENDA`, `DIM_MIGRACION`, `DIM_UBICACION`, `DIM_TIEMPO` y `DIM_ESTADO_OCUPACIONAL`.

El modelo permite analizar medidas relacionadas con los ingresos laborales, las horas trabajadas, los ingresos provenientes de otras fuentes y el tiempo de búsqueda de empleo, considerando diferentes características demográficas, del hogar, migratorias, geográficas, temporales y ocupacionales.


2. Modelo dimensional

Se seleccionó un modelo estrella debido a que permite organizar la información alrededor de una tabla de hechos central, relacionada directamente con diferentes dimensiones descriptivas. Esta estructura facilita la realización de consultas analíticas y permite estudiar los hechos desde múltiples perspectivas.

La tabla central `FACT_SITUACION_LABORAL` contiene las medidas relacionadas con la situación laboral de las personas encuestadas y las claves que permiten relacionarla con las diferentes dimensiones.

Las dimensiones proporcionan el contexto necesario para analizar dichas medidas. De esta manera, la información puede ser consultada según las características de la persona, el hogar, la ubicación geográfica, el período de tiempo, la situación migratoria y el estado ocupacional.

Figura 1. Modelo estrella propuesto para la bodega de datos GEIH.



3. Granularidad de la tabla de hechos

La granularidad definida para `FACT_SITUACION_LABORAL` corresponde a **una persona encuestada en un período determinado de la GEIH.**

Por lo tanto, cada registro de la tabla de hechos representa la situación laboral de una persona para un período específico de la encuesta, relacionándola con sus características personales, las características de su hogar y vivienda, su información migratoria, su ubicación geográfica, el período de referencia y su estado ocupacional.

Esta definición permite analizar las medidas de la tabla de hechos desde diferentes dimensiones y realizar comparaciones entre personas, períodos, ubicaciones y categorías ocupacionales.

Las medidas pueden no aplicarse a todas las personas. Por ejemplo, las horas trabajadas y los ingresos laborales están principalmente relacionados con personas ocupadas, mientras que las semanas de búsqueda de empleo corresponden a personas que se encuentran buscando trabajo. En estos casos, el proceso ETL deberá representar adecuadamente los valores que no sean aplicables.

4. Dimensiones de la bodega de datos

4.1. Dimensión Persona — DIM_PERSONA

Propósito

La dimensión DIM_PERSONA permite almacenar las características demográficas y sociales de cada persona encuestada que son relevantes para analizar su situación laboral.

Granularidad

La granularidad corresponde a **una persona encuestada**.

Atributos

- id_persona
- edad
- sexo
- parentesco_jefe
- estado_civil
- nivel_educativo

Justificación

Esta dimensión es necesaria porque las características individuales permiten segmentar y comparar los indicadores laborales de diferentes grupos de población. Por ejemplo, permite analizar los ingresos laborales o las horas trabajadas según rangos de edad, sexo, nivel educativo, estado civil o relación con el jefe del hogar.

La información utilizada para esta dimensión proviene principalmente del archivo **Características generales, seguridad social en salud y educación**, perteneciente a la GEIH.

El uso de una dimensión independiente para las características de la persona permite mantener separada la información descriptiva de los indicadores cuantitativos almacenados en la tabla de hechos y facilita las consultas analíticas sobre diferentes grupos de población.

4.2. Dimensión Hogar y Vivienda — DIM_HOGAR_VIVIENDA

Propósito

La dimensión DIM_HOGAR_VIVIENDA permite representar las características del hogar y de la vivienda en la que reside la persona encuestada.

Granularidad

La granularidad corresponde a **un hogar encuestado**.

Atributos

- id_hogar
- tipo_vivienda
- cuartos
- acceso_servicios
- personas_hogar

Justificación

Esta dimensión permite incorporar al análisis laboral el contexto habitacional y familiar de las personas. Características como el tipo de vivienda, el número de cuartos, la cantidad de

personas que conforman el hogar y el acceso a servicios públicos pueden utilizarse para identificar diferencias en las condiciones de vida asociadas con la situación laboral.

El atributo `acceso_servicios` representa una característica derivada a partir de la información disponible sobre los servicios públicos del hogar. Durante el proceso ETL se establecerá una regla para consolidar esta información en un único atributo.

La información para esta dimensión proviene principalmente del archivo **Datos del hogar y la vivienda**, perteneciente a la GEIH.

La separación de esta información en una dimensión propia permite analizar los indicadores laborales considerando el entorno familiar y habitacional de la persona, sin mezclar estos atributos con las características individuales.

4.3. Dimensión Migración — DIM_MIGRACION

Propósito

La dimensión DIM_MIGRACION permite incorporar al análisis las características relacionadas con la movilidad y los antecedentes migratorios de las personas encuestadas.

Granularidad

La granularidad corresponde a **la información migratoria asociada a una persona encuestada**.

Atributos

- `id_migracion`
- `nacio_en_municipio`
- `residencia_hace_5anios`
- `razon_migracion`

Justificación

Esta dimensión permite estudiar si existen diferencias en la situación laboral dependiendo del contexto migratorio de la persona. Por ejemplo, se pueden realizar análisis de ingresos, empleo o búsqueda de trabajo considerando el lugar de nacimiento, el lugar de residencia anterior y las razones asociadas a la migración.

La información utilizada para esta dimensión proviene del archivo **Migración**, perteneciente a la GEIH.

La inclusión de esta dimensión permite incorporar la perspectiva migratoria al análisis de los indicadores laborales y facilita la identificación de posibles diferencias entre personas con distintos antecedentes de movilidad territorial.

4.4. Dimensión Ubicación — DIM_UBICACION

Propósito

La dimensión DIM_UBICACION permite analizar la situación laboral teniendo en cuenta el contexto geográfico en el que se encuentra la persona encuestada.

Granularidad

La granularidad corresponde a **una ubicación geográfica asociada al registro de la encuesta**.

Atributos

- id_ubicacion
- departamento
- municipio

Justificación

La ubicación geográfica es una dimensión relevante para el análisis de la situación laboral debido a que las condiciones de empleo, ingresos y búsqueda de trabajo pueden presentar diferencias entre territorios.

Esta dimensión permite realizar comparaciones geográficas de las medidas almacenadas en la tabla de hechos. Por ejemplo, permite analizar los ingresos laborales o las horas trabajadas según departamento o municipio.

Los datos de la GEIH incluyen variables de identificación geográfica como el departamento y variables relacionadas con el área de encuesta. Durante el proceso ETL se establecerá la transformación correspondiente para obtener el nivel geográfico utilizado por la bodega, especialmente para el atributo municipio.

La existencia de esta dimensión facilita además la generación de análisis y visualizaciones agrupadas por territorio.

4.5. Dimensión Tiempo — DIM_TIEMPO

Propósito

La dimensión DIM_TIEMPO permite organizar los registros de la bodega según el período en el que fueron recolectados.

Granularidad

La granularidad corresponde a **un período de referencia de la encuesta**.

Atributos

- id_tiempo
- periodo
- mes
- anio

Justificación

Esta dimensión es necesaria para realizar análisis temporales sobre la situación laboral. Permite comparar indicadores entre diferentes meses y años, identificar variaciones en los ingresos laborales, las horas trabajadas o la búsqueda de empleo y analizar la evolución de estos indicadores a través del tiempo.

La GEIH proporciona variables relacionadas con el período, el mes y el año, las cuales pueden utilizarse para construir esta dimensión durante el proceso ETL.

La dimensión temporal permite realizar análisis históricos y facilita la construcción de consultas que comparen los indicadores laborales entre diferentes períodos.

4.6. Dimensión Estado Ocupacional — DIM_ESTADO_OCUPACIONAL

Propósito

La dimensión DIM_ESTADO_OCUPACIONAL permite clasificar a las personas de acuerdo con su situación frente al mercado laboral.

Granularidad

La granularidad corresponde a **una categoría de estado ocupacional asociada a la persona en el período de referencia.**

Atributos

- id_estado
- categoria

Justificación

Esta dimensión es fundamental para interpretar correctamente las medidas de la tabla de hechos. Permite diferenciar los registros según la situación laboral de la persona y realizar análisis específicos para las diferentes categorías.

Por ejemplo, las medidas relacionadas con ingresos laborales y horas trabajadas pueden analizarse principalmente para las personas ocupadas, mientras que las semanas de búsqueda de trabajo resultan relevantes para las personas que se encuentran buscando empleo.

La información necesaria para establecer esta clasificación proviene principalmente del archivo **Fuerza de trabajo**, perteneciente a la GEIH. La categoría almacenada en la

dimensión será obtenida mediante la transformación y clasificación correspondiente durante el proceso ETL.

Esta dimensión permite realizar consultas que comparen las condiciones laborales entre diferentes estados ocupacionales y facilita la interpretación de las medidas almacenadas en la tabla de hechos.

5. Tabla de hechos — FACT_SITUACION_LABORAL

La tabla FACT_SITUACION_LABORAL constituye el centro del modelo estrella y almacena las medidas utilizadas para analizar la situación laboral de las personas encuestadas.

La tabla contiene las claves foráneas que permiten relacionar cada registro con las dimensiones de persona, hogar y vivienda, migración, ubicación, tiempo y estado ocupacional.

Atributos y medidas

- id_hecho: identifica de manera única cada registro de la tabla de hechos.
- id_persona: relaciona el hecho con la dimensión de características personales.
- id_hogar: relaciona el hecho con la dimensión de hogar y vivienda.
- id_migracion: relaciona el hecho con la dimensión de migración.
- id_ubicacion: relaciona el hecho con la dimensión de ubicación.
- id_tiempo: relaciona el hecho con la dimensión temporal.
- id_estado: relaciona el hecho con la dimensión de estado ocupacional.
- ingreso_laboral: representa los ingresos asociados a la actividad laboral de la persona.
- ingreso_otras_fuentes: representa los ingresos provenientes de fuentes diferentes a la actividad laboral.
- horas_trabajadas: representa la cantidad de horas dedicadas al trabajo.
- semanas_buscando_trabajo: representa el tiempo que una persona ha permanecido buscando empleo.

Justificación

La tabla de hechos concentra los principales indicadores cuantitativos necesarios para el análisis de la situación laboral. Al estar relacionada con las diferentes dimensiones, permite analizar cada medida desde múltiples perspectivas.

Por ejemplo, es posible comparar los ingresos laborales según el nivel educativo, analizar las horas trabajadas según ubicación geográfica, estudiar los ingresos según las características del hogar o analizar las semanas de búsqueda de empleo según las características demográficas y migratorias.

De esta manera, la tabla de hechos proporciona los valores cuantitativos y las dimensiones proporcionan el contexto necesario para interpretarlos.

6. Relación entre las dimensiones y la tabla de hechos

El diseño propuesto permite consultar la información desde diferentes perspectivas sin necesidad de trabajar directamente sobre los archivos originales de la GEIH.

La dimensión DIM_PERSONA permite analizar los indicadores según características demográficas y sociales. DIM_HOGAR_VIVIENDA permite incorporar las condiciones del hogar y la vivienda. DIM_MIGRACION permite estudiar la relación entre los antecedentes migratorios y la situación laboral. DIM_UBICACION permite realizar comparaciones territoriales. DIM_TIEMPO permite observar la evolución de los indicadores y DIM_ESTADO_OCUPACIONAL permite diferenciar los resultados según la situación de las personas frente al mercado laboral.

La combinación de estas dimensiones con las medidas de FACT_SITUACION_LABORAL permite construir consultas analíticas orientadas a identificar patrones, diferencias y tendencias dentro de la población estudiada.

7. Conclusiones

El modelo estrella propuesto permite organizar la información de la Gran Encuesta Integrada de Hogares en una estructura orientada al análisis de la situación laboral de la población. La

tabla de hechos concentra las principales medidas de interés, mientras que las dimensiones proporcionan diferentes perspectivas para interpretar dichas medidas.

La separación de la información en dimensiones de persona, hogar y vivienda, migración, ubicación, tiempo y estado ocupacional facilita la realización de consultas analíticas y permite identificar diferencias en los indicadores laborales según las características de la población y su contexto.

El modelo constituye la base para las siguientes fases del proyecto, en las cuales se realizará el proceso ETL para transformar y cargar la información de los archivos originales de la GEIH en la bodega de datos y posteriormente ejecutar consultas analíticas y generar visualizaciones a partir de la información almacenada.