

Proyecto 1: GEIH — Gran Encuesta Integrada de Hogares (DANE)
Informe de resultados — Fase E

Geraldine Florez Rico (2269476)
Daniela Orrego Alfonso (2510208)
Juan Camilo Velez Ospina (2510206)
Andrés Felipe Salcedo Buitrago
(2359304-3743)

<https://github.com/JuanCVO/Proyecto-1-IC>
D.git

INTRODUCCIÓN A LA CIENCIA DE DATOS

Ing. Héctor Fabio Ocampo Arbeláez

Universidad del Valle
Tuluá, Valle del Cauca
Semestre II - 2026

1. Preguntas de negocio abordadas

La bodega de datos se diseñó para responder preguntas sobre la situación laboral de la población encuestada en la GEIH, cruzando la tabla de hechos FACT_SITUACION_LABORAL con sus seis dimensiones. Concretamente, este proyecto buscó responder:

- ¿Cómo se distribuye la población entre ocupados, desempleados e inactivos, y esa distribución cambia según el sexo?
- ¿Qué departamentos presentan las mayores tasas de desempleo?
 - ¿Existe relación entre el nivel educativo y el ingreso laboral promedio, y esa relación es igual para hombres y mujeres?
 - ¿Las condiciones de la vivienda (tipo y acceso a servicios públicos) están asociadas al ingreso laboral de sus habitantes?
- ¿El antecedente migratorio (haber nacido o no en el municipio de residencia actual) influye en el ingreso o el estado ocupacional?
- ¿Cómo varían las horas trabajadas promedio según el rango de edad de las personas ocupadas?

2. Diagrama de la bodega de datos

Se utilizó un modelo estrella compuesto por la tabla de hechos

Elemento	Registros
DIM_PERSONA	66.285
DIM_HOGAR_VIVIENDA	24.260
DIM_MIGRACION	66.285
DIM_UBICACION	33
DIM_ESTADO_OCUPACIONAL	3
FACT_SITUACION_LABORAL	53.131
DIM_TIEMPO	1 periodo (202606)

Este diseño permite analizar las medidas de ingreso, horas trabajadas y búsqueda de empleo desde múltiples perspectivas sin tocar los archivos originales del DANE.

Modelo estrella — Bodega de datos GEIH




Figura 1. Modelo estrella de la bodega de datos GEIH

3. Hallazgos clave

La Fase D (entrega/fase_d_visualizaciones.ipynb) generó 8 visualizaciones a partir de la bodega:

- (1) personas desempleadas según semanas de búsqueda de empleo — usada como proxy de serie temporal, ya que la bodega solo tiene cargado el período 202606 y no existe todavía una serie calendario real—,
- (2) distribución de la edad de la población encuestada,
- (3) población por estado ocupacional y sexo,
- (4) ingreso laboral promedio por nivel educativo y sexo,
- (5) tasa de desempleo por departamento (top 15) y sexo,
- (6) ingreso promedio por tipo de vivienda y acceso a servicios,
- (7) horas trabajadas vs. ingreso laboral.
- (8) ingreso promedio por razón de migración y estado ocupacional. De estas, se profundiza a

continuación en las tres que arrojaron las señales más claras y ya cuentan con captura de la visualización correspondiente.

Hallazgo 1 — Menor participación laboral y mayor desempleo entre las mujeres




Figura 2. Población por estado ocupacional y sexo, período 202606 (Visualización 3, Fase D).

En el período 202606, la tasa de desempleo de las mujeres (11.1%, 1.650 desempleadas sobre 14.850 en la fuerza laboral) es notablemente más alta que la de los hombres (7.7%, 1.350 sobre 17.550). La diferencia más marcada, sin embargo, está en la inactividad: el 48.6% de las mujeres encuestadas (14.050 de 28.900) se encuentra en estado inactivo, frente a sólo el 27.0% de los hombres (6.500 de 24.050). Esto indica que la brecha de género en esta muestra se explica más por una menor participación en la fuerza laboral (inactividad) que por el desempleo en sí.

Hallazgo 2 — Brecha de ingresos por nivel educativo y sexo




Figura 3. Ingreso laboral promedio por nivel educativo y sexo, personas ocupadas, período 202606 (Visualización 4, Fase D).

El ingreso laboral promedio aumenta de forma consistente con el nivel educativo para ambos sexos, pero la brecha entre hombres y mujeres se amplía en los niveles más altos: en el nivel 13 (código GEIH P3042) los hombres ganan en promedio cerca de \$9.950.000 frente a \$7.650.000 de las mujeres, una brecha de aproximadamente 23%; en el nivel 11 la brecha es similar (cerca del 24%). Esto sugiere que la diferencia salarial entre sexos no se explica únicamente por diferencias en escolaridad, sino que persiste incluso entre personas con el mismo nivel educativo.

Hallazgo 3 — Ingreso según razón de migración




Figura 4. Ingreso laboral promedio por razón de migración (código GEIH P3375) y estado ocupacional, período 202606 (Visualización 8, Fase D).

Entre las personas ocupadas, el ingreso laboral promedio varía según la razón de migración reportada (código GEIH P3375): el código 9 registra el ingreso más alto (\$1.906.317/mes), seguido del código 1 (\$1.671.465/mes) y del código 2, el más bajo (\$1.547.907/mes) — una diferencia de aproximadamente 23% entre el grupo de mayor y menor ingreso. Como era esperado, las columnas de Desempleado e Inactivo no muestran valores, ya que el ingreso laboral solo aplica a personas ocupadas. Los códigos de esta variable aún no se mapean a sus etiquetas legibles del diccionario del DANE (ver Limitaciones), por lo que esta lectura es preliminar hasta completar ese mapeo.

4. Limitaciones

- La bodega solo tiene cargado un período (202606), por lo que DIM_TIEMPO no permite construir una serie de tiempo calendario real. La Visualización 1 de la Fase D usa las semanas de búsqueda de empleo como proxy temporal, una elección metodológica documentada explícitamente en el notebook para no inventar datos de otros meses.
- El ingreso laboral es autorreportado por los encuestados, lo cual puede introducir subdeclaración, especialmente en los tramos de ingresos más altos.
- Varias variables categóricas (nivel_educativo, tipo_vivienda, razon_migracion) se mantuvieron con su codificación numérica original del DANE en las dimensiones, sin mapear a etiquetas legibles, porque el equipo no contaba todavía con una fuente confiable del diccionario exacto de su versión de la encuesta. Esto limita la interpretación directa de los gráficos que las usan.
- Las medidas de horas trabajadas e ingreso laboral no aplican a toda la población (por ejemplo, personas inactivas), por lo que los promedios reportados corresponden únicamente al subconjunto de personas para las que la medida tiene sentido (principalmente ocupados).
- La relación entre horas trabajadas e ingreso laboral (Visualización 7) resultó positiva pero débil y dispersa (el ingreso depende de otros factores como tipo de ocupación o formalidad), y la dimensión geográfica solo llega a nivel de departamento/municipio, sin distinguir zona urbana o rural.

5. Próximos pasos

Cargar más períodos mensuales de la GEIH en la bodega, de forma automatizada, para reemplazar el proxy de semanas de búsqueda por una serie de tiempo calendario real.

- Completar el diccionario de equivalencias del DANE para nivel_educativo (P3042), tipo_vivienda (P4010) y razon_migracion (P3375), y actualizar las dimensiones con las etiquetas legibles en lugar de los códigos numéricos.
- Complementar los hallazgos visuales con pruebas estadísticas formales (correlación, regresión, diferencia de medias) que confirmen si las diferencias por sexo, departamento y razón de migración son significativas.

- Investigar qué otras variables (tipo de ocupación, formalidad) explican mejor el ingreso laboral, dado que las horas trabajadas por sí solas mostraron una relación débil con el ingreso.
- Construir un dashboard interactivo (Power BI, Tableau o Looker Studio) conectado a la bodega, para que usuarios no técnicos exploren los indicadores laborales por su cuenta.

Conclusión

La bodega permite integrar información laboral, demográfica, territorial, residencial y migratoria en una estructura analítica común. Las consultas realizadas muestran diferencias en la composición ocupacional por sexo, en los ingresos laborales asociados a los códigos educativos y en el desempleo territorial. Para fortalecer el análisis, el siguiente paso es ampliar la cobertura temporal, documentar las categorías de las variables y profundizar en la segmentación de los indicadores.